



Rheinische
Hochschule
Köln

Früherkennung von Windturbinenausfällen

Benchmark zwischen Semi-supervised vs. Supervised


Kevin Kita · Jakob Fankhauser

Applied Machine Learning · MTM-Automatisierungstechnik · SS2026

Inhaltsverzeichnis

1. Problemstellung und Relevanz
2. CARE-Datensatz
3. Forschungsfrage
4. Zentrale Erkenntnisse der EDA
5. Datenvorbereitung
6. Semi-supervised Modelle & Supervised Modelle
7. Ergebnisse, Detailanalyse und Trainingsverlauf
8. Fazit und Limitation



1. Problemstellung und Relevanz



2. CARE-Datensatz

➔ **Datensatz:** Care_to_Compare (Zenodo 2025). 3 reale Windparks (A,B,C), insgesamt 89 Turbinen-Jahre Beobachtungszeit

Windpark A	Windpark B
Hauptanalyse & EDA 22 Events 5 Turbinen 81 Features 11 Anomalien	Replikation 15 Events 9 Turbinen 257 Sensor Features 6 Anomalien



3. Forschungsfrage

Bringt die explizite Modellierung der Zeitstruktur (CNN, LSTM, Conv-AE) einen Mehrwert gegenüber Modellen mit zeitlich isolierter Fenster-Statistiken?

Semi-supervised

Lernt nur den Normalbetrieb.
Abweichung bedeutet Anomalie

- Isolation Forest (tabellarisch)
- One-Class SVM (tabellarisch)
- Conv-Autoencoder (temporal, rohe Fenster)




Supervised

Pseudo-Labels: Prediction-Teil = Anomalie.

- Random Forest (tabellarisch)
- LightGBM (tabellarisch)
- 1D-CNN + LSTM (temporal, rohe Fenster)

4. Zentrale Erkenntnisse der EDA

- ➡ 40 NaN-Werte bei 1,2 Mio. Zeitstempeln → sehr hohe Datenqualität
- ➡ 75% Normalbetrieb → extremes Klassenungleichgewicht
- ➡ 0,04 max. Korrelation → Kein Einzelsensor als Frühwarnung nutzbar
- ➡ 4 Ausfalltypen → Hydraulik mit 6x dominant → Daraus resultiert die Binärklassifikation
- ➡ Auf Einzelzeitpunkt-Ebene (Normal;Fehler) nicht unterscheidbar → Stärkstes Argument für zeitliche Modelle



4. Zentrale Erkenntnisse der EDA

Abb. 11: Getriebeausfall (Event #72)






Abb. 12: Hydraulikausfall (Event #73)




5. Datenvorbereitung

1. Gleitende Fenster




- 144 Schritte = 24 Stunden bei 10 Minuten Auflösung
- Schrittweite 6 = 1 Stunde
- Kausal: nur Vergangenheitsdaten, kein Blick in die Zukunft

2. Feature Extraktion




- Tabellarisch: 7 Statistiken je Sensor (μ , σ , min, max, q10/50/90)
- Temporal: rohe 24h-Fenster für CNN, LSTM, Conv-AE

3. LOAO-Validierung



- Leave-One-Anomaly.Out: genau 1 Anomalie-Event als Test, Rest trainiert
- 11 Folds für Park A, 6 Folds für Park B
- Stellt sicher, dass das Modell das getestete Event nicht kennt

4. Skalierung



- StandardScaler nur auf Trainingsdaten je Folds (kein Data Leakage)
- Training nur auf Normalbetrieb (Status 0)
- Anomalie-Label = gesamter Prediction-Teil (Degradationsbeginn ist nicht bekannt)

Labeldefinition: Der gesamte Prediction-Teil = Anomalie, Normalbetrieb (Status 0) = negativ.

Begründung: Der tatsächliche Degradationsbeginn ist unbekannt. Ein willkürliches Vorlaufzeitfenster (z.B. 7 Tage) verschiebt das Problem nur.

6. Semi-supervised Modelle

Isolation Forest

- Tabellarisch
- 200 Bäume
- Isolierte Anomalien durch zufällige Splits.
- Schneller isoliert = anomaler
- Schwelle: 99. Prozent

One-Class SVM

- Tabellarisch
- RBF-Kern.
- Lernt Grenze um Normaldaten im Feature Raum
- Schwelle: 99. Prozent

Conv-Autoencoder

- Temporal
- Encoder: Conv1D(32-16-16)
- Decoder: gespiegelt
- Rekonstruktionsfehler = Score
- Loss: MSE, 15 Epochen

- Alle drei Modelle trainieren ausschließlich auf Normalbetrieb (Status 0) - kein einziges Anomalie-Beispiel nötig

6. Supervised Modelle

- **Alle DL-Modelle:** Adam ($lr=1e-3$), 15 Epochen, Batch 256, Dropout 0,3

Random Forest	LightGBM	1D-CNN	LSTM
• Tabellarisch • 300 Bäume, balanced	• Tabellarisch • 300 Bäume, balanced	• Temporal • Conv(32) -> Conv(64) -> Dense(32)	• LSTM(32) -> Dense(16)

- **Pseudo-Label-Annahme:** Der gesamte Prediction-Zeitraum gilt als Anomalie. Das ist eine Vereinfachung – in Wirklichkeit enthält dieser Zeitraum auch noch normalen Betrieb. Die Class Weights gleichen die Schiefeite aus, aber das Label-Rauschen bleibt.

7. Ergebnisse - ROC-AUC & F1

Park	Paradigma	Modell	ROC-AUC	F1
A	semi	Isolation Forest	0,675	0,230
A	semi	One-Class SVM	0,695	0,283
A	semi	Conv-Autoencoder	0,627	0,199
A	supervised	Random Forest	0,479	0,014
A	supervised	LightGBM	0,436	0,127
A	supervised	1D-CNN	0,416	0,212
A	supervised	LSTM	0,411	0,229
B	semi	Isolation Forest	0,526	0,087
B	semi	One-Class SVM	0,553	0,210
B	semi	Conv-Autoencoder	0,599	0,392
B	supervised	Random Forest	0,550	0,033
B	supervised	LightGBM	0,509	0,343
B	supervised	1D-CNN	0,544	0,432
B	supervised	LSTM	0,493	0,401

7. Detailanalyse - OC-SVm, Park A

Confusion Matrix

	Pred: Normal	Pred: Anomalie
Tats: Normal	13.293	162
Tats: Anomaly	2.840	593

Recall je Ausfalltyp

Ausfalltyp	Recall
Generatorlager	0,356
Hydraulik	0,088
Getriebe	0,064
Transformator	0,000

Kennzahlen

1,2%

Fehlalarmrate
Sehr konservativ

17,3%


Recall Anomalie
Nur jedes 6. Fenster erkannt

78,5%


Präzision Anomalie
Wenn Alarm -> oft richtig

7. Trainingsverlauf (Fold 1, Park A)


Trainingsverlauf (Windpark A, Fold 1)



- Training-MSE sinkt von 0,275 auf ca. 0,105 und läuft ab Epoche 8 in ein Plateau
- Training und Validierung konvergieren eng.
- Kein Overfitting: Modell lernt ein stabiles Bild des Normalbetriebs



- Training-Loss dauerhaft über Validierungs-Loss -> Class Weights Gewichten Fehler auf der seltenen Anomalie Klasse hoch, das treibt den Trainings Loss
- Auf Validierung werden Class Weights nicht angewendet



- Beide Kurven über 0,99 -> das Modell trennt bekannte Muster fast perfekt
- Das Modell lernt die bekannten Anomalien-Muster auswendig, generalisiert aber nicht auf unbekannte Events

8. Fazit & Limitationen

Fazit

- Semi-supervised schlägt supervised auf Park A klar: OC-SVM 0,695, alle supervised unter 0,5. Auf Park B sind die Ansätze vergleichbar.
- Zeitstruktur bringt keinen Vorteil. Conv-AE (temporal) liegt hinter OC-SVM und IsoForest (beide tabellarisch)
- Entscheidender Faktor ist das Lernparadigma (semi vs. Supervised), nicht die Architektur (tabellarisch vs. Temporal)
- Pseudo Labels scheitern auf Park A: zu kurze Anomalie Verläufe (-10Tage), der Prediction Teil enthält zu viel Normaldaten
- Alle Werte zwischen 0,4 und 0,7. Das ist konsistent mit der bekannten Schwierigkeit des Care-Benchmarks. Kein Modell löst das Problem vollständig.

Limitation

- Wenig Anomalien: 11 Events (A), 6 Events (B) - Metriken streuen stark
- Ein Seed: Zufällige Effekte nicht ausgemittelt, DL-Ergebnisse nicht reproduzierbar abgesichert
- Pseudo Labels: Annahme, dass der gesamte Prediction Teil eine Anomalie ist. Trifft auf Park A nicht zu
- LOAO zu optimistisch: Dieselbe Turbine kann in Training und Test vorkommen
- Ein Modell für alles: Seltene Ausfalltypen (Transformator 1x) werden leicht übersehen.

Diese PowerPoint-Präsentation wurde von
Jakob Fankhauser und Kevin Kita erstellt

Kevin Kita · 132261089 · MTMII AUT
Jakob Fankhauser · 132261103 · MTMII AUT

Schaevenstraße 1a-b | 50676 Köln | Tel. 0221-20 30 20
www.rhk-koeln.de